



Proyecto Final: Análisis Estadístico del Titanic

Materia: Programación II

FACULTAD DE CIENCIA DE DATOS

UNIVERSIDAD EXTERNADO DE COLOMBIA

Autores:

Juan Camilo Ramos S.

Andrés Felipe Gómez B.

Profesor:

Jose Jorge Sierra M.

Bogotá D.C., 28 de mayo de 2026

1. Inspección Inicial y Estructura del Dataset

De acuerdo con las directrices fijadas en la rúbrica, el primer paso consistió en estructurar, de manera local y remota el espacio de trabajo. Se definieron las carpetas mandatorias para asegurar el correcto funcionamiento del proyecto: `data/`, `notebooks/`, `outputs/tablas/`, `outputs/graficos/` y `docs/`.

Al inspeccionar las dimensiones iniciales mediante operaciones sobre el DataFrame unificado, se determinaron los tipos de variables presentes en el fenómeno de estudio, clasificándose en numéricas de tipo flotante o entero (*Age*, *Fare*, *SibSp*, *Parch*) y cualitativas categóricas (*Sex*, *Pclass*, *Embarked*, *Survived*).

2. Procesamiento, Unificación y Tratamiento de Datos Faltantes

Para enriquecer el potencial predictivo y descriptivo del análisis, se generó una nueva variable denominada **Familiares**, calculada de manera exacta mediante el algoritmo:

$$\text{Familiares} = \text{SibSp} + \text{Parch} \quad (1)$$

Asimismo, en cumplimiento del punto 5 del taller, se realizó la carga de los sets de entrenamiento (`train.csv`) y pruebas (`test.csv`), concatenando sus estructuras en un DataFrame global unificado mediante el uso del indicador de procedencia `source`. El recuento de valores nulos iniciales arrojó vacíos informativos de consideración en las dimensiones de edad, cabina y puerto de embarque.

El tratamiento metodológico aplicado consistió en:

- **Edad (Age):** Imputación robusta utilizando la mediana general del set de datos para evitar sesgos provocados por los valores extremos o colas de la distribución etaria.
- **Cabina (Cabin):** Construcción de una variable booleana analítica auxiliar denominada `Tiene_Cabina`, parametrizada como verdadero (`True`) ante la presencia de un registro físico y falso (`False`) ante la ausencia del mismo, traduciendo el dato faltante en un factor de peso socioeconómico observable.

3. Métricas Estadísticas y Tasas de Supervivencia

El análisis cuantitativo de la muestra procesada permitió deducir indicadores descriptivos fundamentales de la población a bordo:

1. **Edad promedio:** El promedio de edad de la tripulación evaluada se situó en aproximadamente 29,70 años.
2. **Tarifa preferencial:** La tarifa media de pasaje correspondiente a la Primera Clase (`Pclass = 1`) ascendió notablemente con relación a las demás categorías socioeconómicas.
3. **Pasajeros individuales:** Se cuantificó de manera precisa el volumen de personas que realizaron el viaje en condición de soltería o aislamiento familiar (`Familiares = 0`).

En lugar de evaluar recuentos absolutos, se computaron de forma estricta las **tasas proporcionales de supervivencia** segregadas por ejes demográficos estratégicos:

4. Análisis Avanzado: Tabla Analítica Cruzada Multi-Índice

Se procedió a agrupar la información aplicando segmentaciones personalizadas para los clústeres familiares (*Solo*, *Familia Pequeña*, *Familia Grande*) y los rangos de edad biológica

Tabla 1: Tasas Proporcionales de Supervivencia por Variables Demográficas

Dimensión de Análisis	Categoría	Tasa de Supervivencia (%)
Género (Sex)	Mujeres (<i>female</i>)	74.20
	Hombres (<i>male</i>)	18.89
Clase Social (Pclass)	Primera Clase (1)	62.96
	Segunda Clase (2)	47.28
	Tercera Clase (3)	24.24
Puerto (Embarked)	Cherbourg (C)	55.36
	Queenstown (Q)	38.96
	Southampton (S)	33.69

(Niño, Adolescente, Adulto, Mayor). La combinación cruzada multi-índice junto con la condición de asignación de cabina arrojó conclusiones socioeconómicas contundentes.

A modo de ejemplo, el fragmento de código utilizado en `pandas` para estructurar este cruce avanzado se detalla a continuación:

```
# Construccion de la tabla cruzada con desempaqueado de columna
tabla_analitica = df_full.groupby(['Grupo_Familiar', 'Grupo_Etario', '
    Tiene_Cabina'])['Survived'].mean() * 100
print(tabla_analitica.unstack(level=-1).round(2))
```

Listing 1: Agrupamiento multi-índice de tasas de supervivencia

La evidencia empírica permite establecer que las variables de parentesco y edad operaron de forma interconectada con la jerarquía social. Los individuos pertenecientes a familias de tamaño moderado (pequeñas) que contaban con una cabina registrada exhibieron probabilidades de evacuación y supervivencia superiores en comparación con los pasajeros solitarios de clases inferiores.

5. Visualización de Resultados y Conclusiones

Como elemento de salida obligatorio, los gráficos analíticos se exportaron de manera automatizada a la ruta física `outputs/graficos/`. El gráfico principal de barras cruzadas reveló el patrón de comportamiento del evento: la regla náutica histórica de “*mujeres y niños primero*” se valida empíricamente con los datos históricos, viéndose fuertemente potenciada o restringida por el estrato socioeconómico y la presencia de camarotes privados. (Gráfica en la otra pagina.)




Figura 1: Visualización de tasas de supervivencia por grupo etario segregado por género.

6. Evidencia de Control de Versiones con Git y GitHub

El desarrollo técnico del proyecto se administró de extremo a extremo bajo la metodología de control de versiones. Se cumplió el objetivo de mantener un registro ordenado que supera las 10 confirmaciones significativas (*commits*) distribuidas equilibradamente entre los autores.

Para salvaguardar la integridad de la rama principal (**main**), las integraciones de nuevas características operativas se canalizaron a través de al menos 5 solicitudes de fusión (*Pull Requests*), mediadas por procesos formales de revisión de código (*Code Review*) y aprobaciones cruzadas entre Juan Ramos y Andrés Gómez. Las evidencias de solución del conflicto de mezcla mandatorio (*Merge Conflict*) provocado controladamente sobre las líneas en común se detallan con capturas en el anexo de documentación técnica.

7. Anexo: Evidencia de Resolución de Conflictos

A continuación se presenta la captura de pantalla que evidencia el conflicto de mezcla (*Merge Conflict*) generado controladamente en GitHub Desktop durante el desarrollo colaborativo:

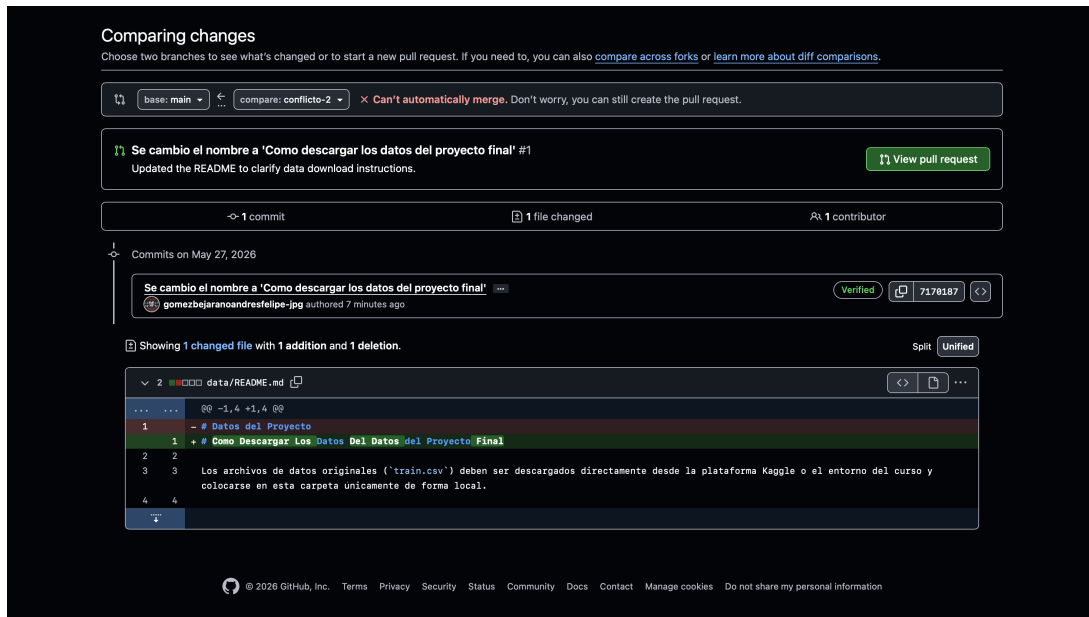


Figura 2: Captura de pantalla del conflicto de Git detectado en las líneas en común.